

딥러닝 알고리즘을 적용한 컬처마이닝

이준서* · 임상순**

< Abstract >

Culture mining with deep learning algorithms

This paper is a paper conceived to improve the Cultural Image Frame Network (CIFN) by utilizing deep learning-based image learning datasets that have recently received much attention in major research fields such as computer vision and Natural Language Processing (NLP). In particular, CNN, which uses convolutional filters for images to calculate quickly and considers the entire image, including specific objects as well as backgrounds, is a very suitable algorithm for extracting cultural elements that constitute the cultural image frame of this culture mining study. In addition, by utilizing images in the form of refined images verified with deep learning experimental and test datasets, the limitations of existing research, such as (1) reliability of tagging information, (2) inaccuracy of the segmentation method, and (3) redundancy of images, can contribute to more sophisticated research.

Field : 의미론(Semantics)

Keywords : Deep Learning, CEMS (Cultural Element Mining System), CIFN (Cultural Image Frame Network), Cultural Element, Cultural Image Frame(CIF), CNN, RNN

1. 들어가며

컴퓨팅 기술의 눈부신 발달로 기존의 소설, 신문, 잡지 등의 문어 텍스트, 그리고 방송, 토론, 일상 대화 등의 구어 텍스트는 물론, 최근 SNS, 블로그, 게시판, 메타버스 등 뉴미디어를 통하여 생성되는 텍스트, 음성, 영상 콘텐츠 등 다양한 형태의 데이터들이 기하급수적으로 쌓이고 있다. 거의 무한에 가까운 이들 빅데이터를 일일이 고찰하는 것은 사실상 불가능한데, 이로부터 가치 있는 정보를 도출하기 위해서는 정제된 데이터베이스 구조로 변형할 수 있는 데이터 처리 기술 및 통계적 데이터 해석 기술은 물론, 종합적인 사고력을 바탕으로 한 융합적 성찰과 통찰력이 뒷받침되어야 한다. 이준서(2021)에서 다문화/이문화/다언어 사회에서 기하급수적으로 쌓여나

* 성결대학교 글로벌물류학부 교수, 의미론

** 성결대학교 컴퓨터공학부 조교수, 컴퓨터공학

이 논문은 2019년 대한민국 교육부와 한국연구재단의 지원을 받아 수행된 연구임.
(NRF-과제번호)(NRF-2019S1A5A2A03046676)

가고 있는 빅데이터 속에서 보다 더 풍부한 부가가치(value)와 데이터 분석을 통한 지식정보(Insight)를 찾아내는 방안으로 독자적인 컬처마이닝(Culture Mining) 기법을 제안하였는데, 문화요소추출시스템(Cultural Image Frame Network, CIFN) 및 문화이미지프레임망(Cultural Image Frame Network, CIFN)은 컬처마이닝에 특화된 플랫폼이라고 할 수 있다.

컬처마이닝은 단일 언어에 국한한 기존의 텍스트마이닝의 한계를 극복한 것으로 다중 언어에 기반해 서로 다른 문화권과의 비교와 대조를 통하여, 보다 더 차별화된 문화요소(Cultural Elements, CE)를 발견해내 이를 활용한 다양한 부가가치와 유용한 지식정보를 얻어낼 수 있다는 점에서 기존의 전통적인 빅데이터 분석방식과 차별화된다. 또한, 제한된 코퍼스 텍스트 데이터에 기반한 문화요소추출시스템(CEMS)을 보완한 이미지 데이터 기반의 문화이미지프레임망(CIFN)은 다수결 투표방식(majority voting)을 통해 문화요소 추출의 객관성을 담보하려한 것으로 평가할 수 있지만, 시스템 설계 및 운영 과정에서 제반 문제점이 노출되어 이에 대한 개선이 시급히 요구되고 있는 상황이다.

최근 딥러닝 기반 학습(Deep Learning, DL)은 컴퓨터 비전 및 자연어 처리 등 주요 연구 분야에서 많은 관심을 받고 있다. 이는 딥러닝 자체의 뛰어난 성능 이외에도 데이터가 지닌 특징(feature)을 추출해 이를 통해 높은 지능이 요구되는 기능(function)을 구현할 수 있기 때문인데, 최근 다양한 연구 분야에서 딥러닝 솔루션을 활용한 시스템 구축이 활발하게 진행되고 있는 것이다.

본고는 특히 컴퓨터 비전(computer vision) 분야의 실험을 위해 제공되는 대용량의 이미지 데이터셋을 활용한 딥러닝 알고리즘을 문화이미지프레임망에 적용함으로써 기존 컬처마이닝 기법의 문제점을 개선하고자 한다.

2. 다중언어 기반 문화이미지프레임망

상술한 바와 같이, 문화이미지프레임망은 기존 문화요소추출시스템(Cultural Element Mining System, CEMS)이 지닌 한계¹⁾를 보완하기 위하여 개발되었다.

1) 문화요소추출시스템의 공개정보는 기존의 특정 대용량 코퍼스를 이용하여 얻어진 값이므로 언어의 동적인 변화를 발견하기 어렵다는 한계가 있다.

Frame, CIF)이 점진적으로 구축되면서 다양한 연구적·교육적·실용적 활용성이 모색되고 있다.



한국의 음주
‘문화이미지프레임’

서양의 음주
‘문화이미지프레임’

중국의 음주
‘문화이미지프레임’

[그림 3. 각 문화권의 차별화된 문화이미지프레임 구현 예시]



[그림 4. 문화이미지프레임을 활용한 콘텐츠 및 플랫폼 개발 예시]

3. 딥러닝 솔루션과 문화이미지프레임망

딥러닝 솔루션들은 기본적으로 우리를 둘러싼 주변 환경 혹은 사용자(user)들로부터 직접 수집할 수 있는 데이터셋들을 바탕으로 정규화된 규칙을 발견할 수 있는 속성들을 도출하게 된다. 이 때, 수집된 데이터셋에 대한 전처리 및 데이터 정제 과정을 통해 정확도를 높일 수 있는 학습 데이터들을 생성하고 이를 인공지능망을 통해 학습시키는 과정을 진행하게 된다. 학습된 데이터는 테스트 데이터와의 검증을 통해 모델의 성능 검증을 진행하게 되며, 성능을 높이기 위해

진행되는 반복되는 학습 과정 중 가장 최적의 모델을 찾아내 딥러닝 시스템에 적용하게 된다.

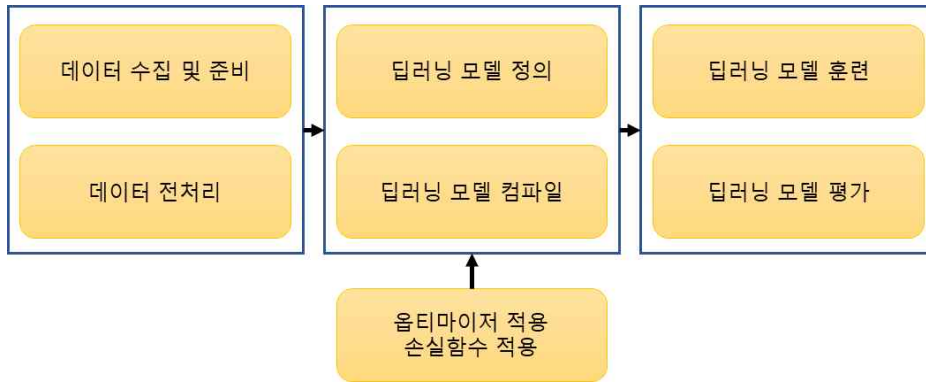


그림 5. 딥러닝 학습 과정

딥러닝은 머신러닝의 하위 분야이며 입력층과 출력층 사이에 히든층을 깊게 배치하여 복잡한 가중치를 계산하고 오차를 업데이트하는 과정을 반복적으로 수행하는 학습과정이다. 즉, 딥러닝 모델을 통해 데이터에서 여러 수준의 표현과 추상화를 학습하게 되는데, 이러한 딥러닝의 구조는 지도 및 비지도 학습 과정 모두에서 성공적인 결과를 담보할 수 있는 것이다.

딥러닝 모델의 기초는 다층 퍼셉트론(Multilayer Perceptron, MLP)으로 볼 수 있다. MLP는 입력 계층과 출력 계층 사이에 여러 층의 은닉 계층을 가지고 있는 피드포워드 신경망이라고 정의할 수 있다. 퍼셉트론은 임의의 활성화 함수를 사용할 수 있는데, 반드시 특정 이진 분류기를 사용할 필요가 없고, 목적에 맞게 다양한 활성화 함수들을 적용할 수 있다. 또한, MLP는 계층적 특징 표현을 학습하는 비선형 변환의 스택 계층으로 해석될 수 있어, 기존의 단일 퍼셉트론으로 풀 수 없던 XOR 문제를 해결하여 인공신경망의 근본적인 구조로 활용되고 있다.

다층 퍼셉트론을 기점으로 특정 목적에 맞는 다양한 모델들이 연구되고 있다. 이미지 처리에 있어서 대표적인 모델이라고 할 수 있는 CNN(Convolutional Neural Network)은 컨볼루션 레이어와 풀링 연산이 반복되는 것이 특징적인 피드포워드 신경망 구조이다. 특히, CNN은 글로벌 및 로컬 기능을 활용하여 이미지 특징을 캡처하고 이미지 분류 성능의 효율성과 정확성을 크게 향상시킬 수 있는데, 다양한 토폴로지를 구성하여 시계열 데이터를 처리하며 특성을 추출하는 분야에서도 효율적으로 사용할 수 있다.

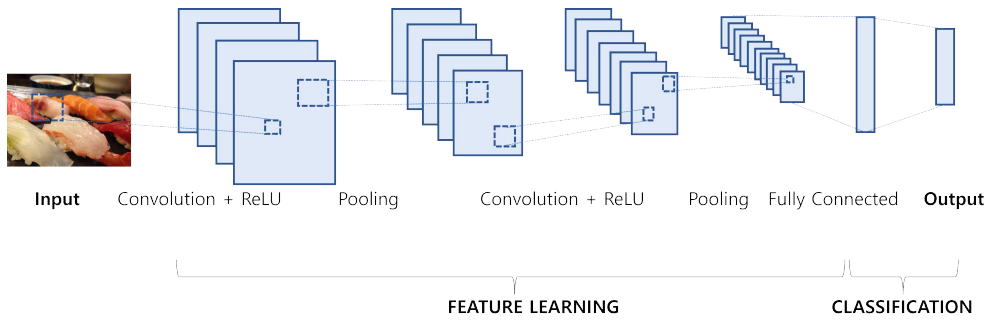


그림 6. 전형적인 convolutional neural network

자연어 처리 및 시계열 데이터를 다루는데 가장 많이 활용되고 있는 모델은 RNN(Recurrent Neural Network)이다. RNN은 시퀀스 모델로써 은닉층에서 적용된 활성화 함수를 통해 나온 출력을 출력층과 은닉층의 다음 연산의 입력값으로 내보내는 특징을 가지고 있다.

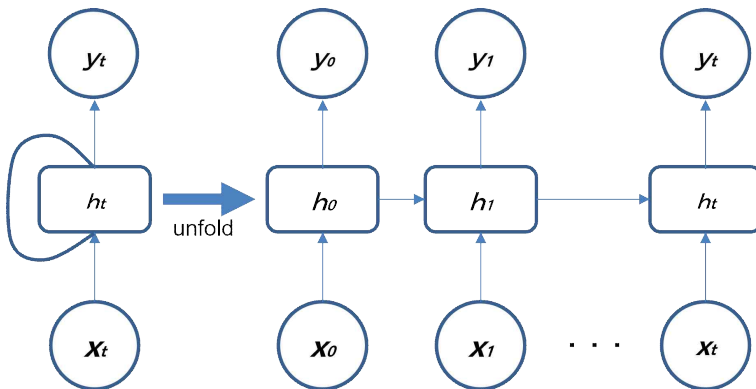
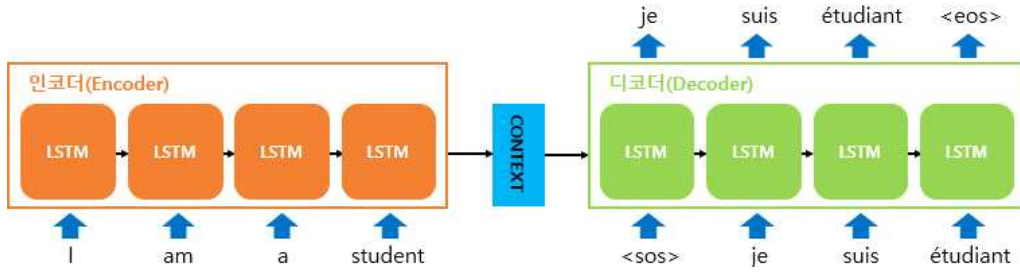


그림 7. RNN의 기본구조

텍스트 데이터의 특성상 각각의 시점은 바로 이전 시점의 은닉층의 메모리 셀 값을 자신의 입력값으로 사용하며 t 시점의 입력값이 $t+1$ 시점 입력값에 영향을 준다. RNN은 입력과 출력의 길이를 다르게 설계할 수 있는 특징으로 인해 다양한 용도로 활용되는데, 다음 그림과 같이 인코더-디코더 모델로 주로 사용하며, 특히 텍스트 감성 분석 및 기계 번역에 잘 작동한다.



[그림 8. 입력, 출력에 따른 RNN 설계]

RNN은 시계열 데이터를 바탕으로 모델링하고 추론하는데 적합한 특징을 가지고 있다. CNN과 달리 RNN에서는 이전 계산을 기억하기 위한 루프와 메모리가 존재한다. 하지만, 시계열 데이터들의 특성상 많은 개수의 유닛으로 구성된 시계열 데이터를 학습할 때 출력값의 오차를 확인한 후, 오차를 줄이기 위해 가중치를 업데이트하는 과정에서 기울기 소실 문제가 발생할 수 있다. 이를 극복하기 위해 LSTM(Long Short Term Memory) 및 GRU(Gated Recurrent Unit) 네트워크와 같은 향상된 모델에서는 실제로 기울기 소실 문제를 극복하기 위해 개방형으로 배포된다.

또한, 이미 레이블링된 데이터를 기반으로 학습하는 딥러닝 모델 이외에도 다양한 데이터들을 재구성할 수 있는 비지도 학습 계열의 우수한 모델들도 다양하게 개발되고 있다. 오토인코더(AE, Autoencoder)는 출력 계층에서 입력 데이터를 재구성할 수 있도록 지원하는 비지도 모델이다. 일반적으로 중간에 위치하게 되는 병목 계층은 입력 데이터의 주요 특징을 표현할 때 사용된다. 이를 바탕으로 잡음 제거 자동 인코더, 주변 잡음 제거 자동 인코더, 희소 자동 인코더, 축소 자동 인코더 및 변형 자동 인코더와 같은 많은 변형 모델들이 개발되고 활용되고 있다.


3.1 문화이미지프레임망 재고

문화이미지프레임(CIF)은 기 수행 연구를 통하여 구축한 문화요소추출시스템(Cultural Element Mining System, CEMS)의 공기빈도에 기반한 어휘 인덱싱 정보 및 실제 사용된 CGM 데이터²⁾를 바탕으로 문화이미지프레임망(Cultural Image Frame Network, CIFN)의 통계적 프로세스와 국가별/세대별/성별 인포먼트 그룹에 의한 다수결(majority voting) 방식에 의해 최종 선정된다.

2) 소비자가 생성하는 미디어(Consumer Generated Media)



[그림 9. 문화이미지프레임 선정과정 예시(모바일 버전)]



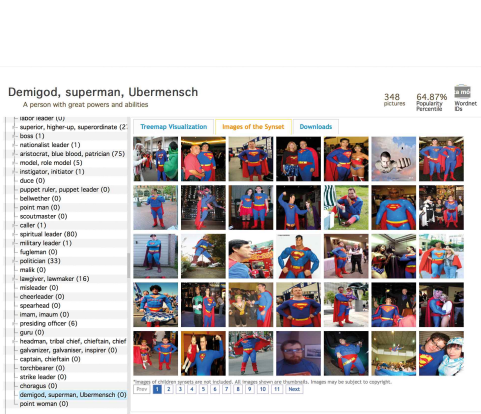
[그림 10. 문화이미지프레임의 이미지 분할(segmentation) 예시]

그러나, 개별 사용자의 이미지 태깅 방식에 크게 의존하는 Google Search API를 통하여 제공되는 이미지 기반으로 선정되는 문화이미지프레임망은 다음과 같은 문제점을 내포하고 있다.

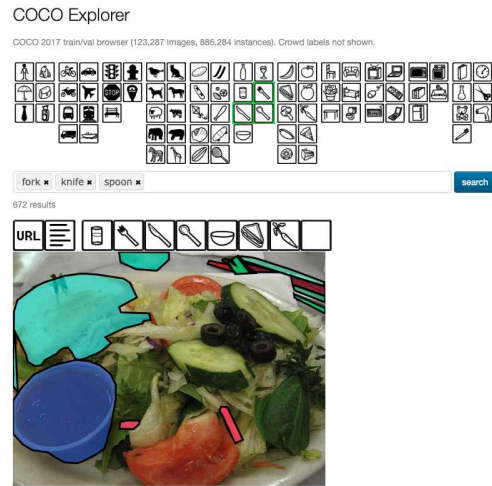
- (1) 이미지 업로드 주체의 주관적인 판단에 기인한 태깅 정보의 신뢰도 문제
- (2) 기계적인 4사분면 이미지 분할(segmentation) 방식(문화요소 특징이 부정확)
- (3) 상위 노출 이미지가 중복됨

이에 대해 워드넷(WordNet³⁾) 분류 체계에 따라 조직화한 이미지 데이터베이스인 이미지넷(imageNet)을 필두로, PASCAL Visual Object Classes, Coco, MIT Indoor Scene, Google Open images, Caltech 101 등에서 컴퓨터 비전 분야의 실험을 위한 정제된 대용량의 이미지 데이터셋을 제공하고 있다.

3) <https://wordnet.princeton.edu>



<https://www.image-net.org>



<https://cocodataset.org>

[그림 11. 딥러닝 기반 이미지 데이터셋 예시]

최근 부동산소수점 연산에 특화된 GPU(Graphics Processing Unit)와 제반 컴퓨팅 환경의 획기적인 발전과 더불어 상술한 바와 같이 다양한 딥러닝 알고리즘 모형이 제안되고 있다. 이미지 처리와 객체 탐지에는 구체적으로 합성곱 신경망(Convolutional Neural Network, CNN)과 반복이 있는 데이터에 적합한 순환신경망(Recurrent Neural Networks, RNN)이 크게 활용되어왔고, 최근에는 Seq2Seq 계열의 학습모델 중 가장 좋은 성능을 보이는 트랜스포머 모델(transformer model)이 각광받고 있다.

이중에서 CNN은 이미지에 컨볼루션 필터를 사용하여 계산이 빠르고, 특정 객체뿐만 아니라 배경(본 연구에서는 ‘프레임(frame)’⁴⁾을 포함한 이미지 전체를 고려할 수 있다는 점에서 본 컬러마이닝 연구의 문화이미지프레임을 구성하는 문화요소 추출에 매우 적합한 알고리즘이라고 할 수 있다. 특히, 딥러닝 실험용 학습 및 테스트 데이터셋으로 검증된 정제된 이미지 형태의 이미지를 활용함으로써 상술한 (1) 태깅 정보의 신뢰성, (2) 이미지 분할(segmentation) 방식의 부정확성, (3) 이미지의 중복성 문제 등 기존 연구의 한계를 크게 극복하여 보다 정교한 컬러마이닝 연구에 기여할 수 있을 뿐만 아니라, 이를 통해 구축되는 컬러마이닝 DB는 궁극적으로는 문화요소 추출 자동화를 위한 학습데이터로써 향후 다양한 활용가치를 담지하고 있다.

3.2 딥러닝 솔루션을 적용한 문화이미지프레임망 개선

본고에서는 문화이미지프레임망 컬러마이닝 시스템 고도화를 위해 CNN 기반의 이미지 분류

4) 인지언어학의 세계에서 자주 등장하는 개념으로 ‘scene’(fillmore, 1975, 1977), ‘script’(Tannen & Wallat, 1993), ‘schema’(Schank & Abelson, 1977), ‘scenario’(Sanford & Garrod, 1977) 등과 일맥상통

기법을 적용하는 방안을 제안한다. 성별, 세대별, 국가별 문화요소는 특정 단어(lexical unit⁵⁾)와 연관된 관련 이미지, 그리고 각 이미지 속의 객체로 이루어진 데이터셋을 대상으로 문화이미지 프레임망에서 시행되는 인포먼트 그룹의 투표로 선정되는 것이다. 이때, 문화이미지프레임망에서는 특정 단어에 대한 연관 이미지를 구글 검색 엔진 API를 통해 수집하고 수집된 이미지에 대해 상위 노출되는 N개의 이미지를 화면에 표시해 주는 절차를 거치게 된다. 인포먼트 그룹은 화면에 표시되는 연관 이미지 및 이들 이미지 속의 객체를 대상으로 문화요소를 선정하는 것으로, 문화이미지프레임망의 통계적인 처리 결과가 실시간으로 반영되는 구조이다. 하지만, 기존 구글 검색 엔진의 특성상 특정 키워드로 이미지 검색을 했을 때 일정한 규칙적인 분류가 이루어지지 않고 해당 키워드와 연관된 이미지를 임의로 나열해주게 된다. 임의로 나열된 상위 N개의 이미지만을 대상으로 한 문화요소의 선정 방식은 문화요소 추출의 정확도 및 선정 결과에 대한 신뢰도에 근본적인 문제점을 내포하고 있다.

이에 본고는 딥러닝 기반 컴퓨터 비전 분야의 실험을 위해 제공되는 정제된 형태의 대용량의 이미지 데이터셋을 문화이미지프레임망에 적용함으로써 문화요소 선정과정의 객관성을 증대시키고자 하는 것으로 대용량의 학습용 데이터를 기반으로 이미지의 특성이 분류된 정제된 형태의 이미지를 활용하는 것이다.

예를 들어, 기존의 방식이 ‘호텔’이라는 단어에 대한 문화요소 선정에 있어서 임의의 순서로 배열된 후보 이미지 리스트에서 이미지를 선택하는 것이었다고 한다면(그림 12 좌), 딥러닝 기반 이미지 후보 리스트는 호텔 침실, 호텔 외관, 호텔 관련 이용 시설 등 호텔이 갖춘 특성에 따라 정렬된 리스트를 바탕으로 분류된 것으로(그림 12 우), 개개 호텔의 특징적인 문화요소 선정에 있어서 수월성을 크게 증대시킬 수 있다. 또한, 문화이미지프레임망에서 한 화면에 표시 가능한 이미지의 개수가 한정적일 수밖에 없는데, 딥러닝 기반 이미지 후보 리스트는 이미지의 유사도 분석 기술을 적용하여 이미지가 중복 표시되는 경우 이를 제거하고 더욱 다양한 종류의 이미지를 화면에 노출시킬 수 있는 시스템으로 확장 가능하다.

실제로 구글의 ML(Machine Learning) Kit를 활용하여 문화이미지프레임망을 고도화시킬 수 있는데, 다음 그림은 구글의 ML Kit 기반 이미지 레이블링을 활용한 예를 나타낸다.

5) 문화이미지프레임을 구성하는 어휘 요소로 프레임넷(<https://framenet.icsi.berkeley.edu>)의 ‘lexical unit’에 해당



그림 12. 구글 ML kit 기반 이미지 레이블링 활용 예

기존의 일반적인 방식의 구글 검색 엔진을 사용하여 호텔과 관련한 이미지를 검색했을 경우 임의로 이미지 리스트가 나열되는 반면, 딥러닝 기반 이미지 분류 솔루션을 활용함으로써 유사 카테고리로 구분된 결과를 가지고 사용자들이 보다 수월하게 문화이미지를 선정할 수 있는 시스템으로 고도화시킬 수 있는 것이다.

구글의 **ML Kit**은 구글에서 독자적으로 개발한 우수한 성능의 기계 학습 솔루션을 서비스에 활용할 수 있도록 지원해 주는 **API**들로 구성되어 있다. 기본적으로 모바일 기기의 환경에 특화되어 실시간 처리가 가능하도록 경량화된 모델들을 지원하며, 기존의 다양한 구글 플랫폼과 연계해서 사용할 수 있는 장점이 있다. 또한, 고도화된 데이터 파이프라인을 활용하여 우수한 기계 학습 모델들을 쉽게 조합하여 사용할 수 있는 환경을 제공한다. 특히, 이미지 레이블링 **API**의 경우, 이미지 데이터들에 대해 빠르게 이미지 정보를 추출하고 해당 이미지의 일반적인 객체, 장소, 활동, 동물의 종류들, 상품 등 다양한 종류의 이미지 카테고리 그룹으로 분류해 줄 수 있는 기능을 제공하고 있다. 학습된 모델을 **Tensorflow Lite** 모델로 변환하여 서비스에 쉽게 적용시킬 수 있는 기능과 함께, 이미지에서 공통적으로 찾을 수 있는 400가지 이상의 카테고리에 대한 분류가 가능할 뿐만 아니라, 이를 확장하여 손쉽게 커스터마이징 할 수 있는 환경을 제공한다. 또한, 상위 레벨 **API**를 제공해 줌으로서 로우 데이터(**Raw data**)나 이미지 전처리등의 과정 없이도 정확도 높은 결과를 도출할 수 있는 장점이 있다.

문화이미지프레임망의 문화요소 추출은 이미지 전체는 물론, 개개 이미지에 표시되는 다양한 객체를 후보 데이터셋으로 선정되는데, 현재의 기계적인 4사분면 이미지 분할(**segmentation**) 방식으로 인해(그림 18) 문화요소의 특징이 부정확하다는 단점을 가지고 있다. 이러한 단점을 보완하기 위해 최근 제안된 딥러닝 기반 사물 인지 기법 중 특정 이미지에서 나타나는 다수의 객체를 빠르게 인식할 수 있는 **YOLO(You Only Look Once)**를 적용할 수 있다. YOLO는 다수

의 객체 인식을 위한 새로운 접근 방식을 제공하며 공간적으로 분리된 경계 상자 및 관련 클래스 확률에 대한 회귀 분석으로 객체 감지를 프레임화한다.

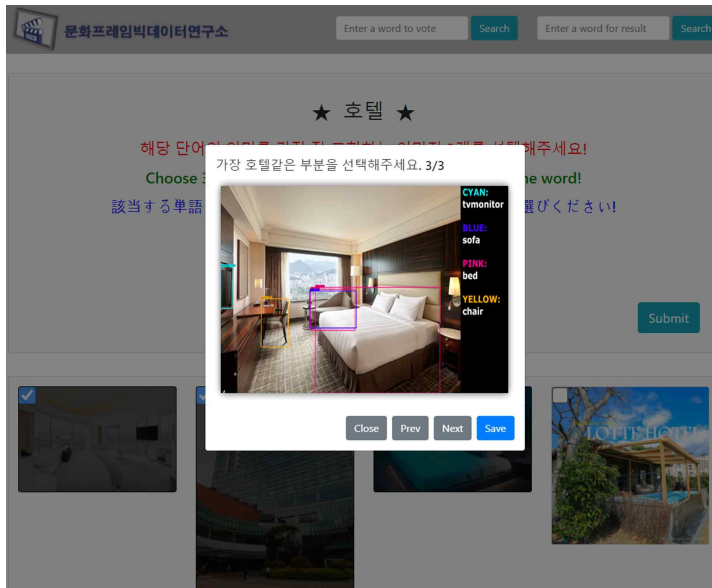


그림 13. YOLO 기반 객체 인식을 활용한 문화이미지프레임망 보팅 시스템 개선 예시

YOLO의 단일 신경망은 한 번의 평가에서 전체 이미지와 관련하여 직접 경계 상자 및 클래스 확률을 예측할 수 있으며, 전체 감지 파이프라인이 단일 네트워크이기 때문에 감지 성능과 관련하여 종단 간 최적화가 가능한 시스템을 지원할 수 있다. 또한, YOLO는 화면에 선택 가능한 영역 이외에도 객체들의 리스트를 텍스트 형식으로 제공할 수 있는데, 기존의 획일적인 4사분면 이미지 분할 방식으로 인한 이미지 객체의 문화요소 특정 문제를 해결할 수 있는 대안으로 활용할 수 있는 것이다.

4. 나가며

본고는 최근 컴퓨터 비전 및 자연어 처리 등 주요 연구 분야에서 많은 관심을 받고 있는 딥러닝 기반 이미지 학습 데이터셋을 활용하여 문화이미지프레임망을 개선하려고 구상한 논문이다. 특히 이미지에 컨볼루션 필터를 사용하여 계산이 빠르고, 특정 객체뿐만 아니라 배경을 포함한 이미지 전체를 고려하는 CNN은 본 컬처마닝 연구의 문화이미지프레임을 구성하는 문화요소 추출에 매우 적합한 알고리즘이라고 할 수 있다. 특히, 딥러닝 실험용 학습 및 테스트 데이터셋으로 검증된 정제된 이미지 형태의 이미지를 활용함으로써 (1) 태깅 정보의 신뢰성, (2) 이미지

분할(segmentation) 방식의 부정확성, (3) 이미지의 중복성 문제 등 기존 연구의 한계를 크게 극복하여 보다 정교한 컬처마이닝 연구에 기여할 수 있을 뿐만 아니라, 이를 통해 구축되는 컬처마이닝 DB는 궁극적으로는 문화요소 추출 자동화를 위한 학습데이터로써 향후 다양한 활용가치를 담지하고 있다.

【참고문헌】

- 강범모(2010), 「공기 명사에 기초한 의미/개념 연관성의 네트워크 구성」, 『한국어의미학』 32, pp.1-28.
- 김흥규, 강범모, 홍정하(2007) 「21세기 세종계획 현대국어 기초말뭉치: 성과와 전망」 『제19회 한글 및 한국어 정보처리 학술대회 논문집』, 한국정보과학회 언어공학연구회, pp.311-316.
- 이준서·한경수(2016) 「다국어 ‘문화요소추출시스템(CEMS)’ 개발 구상」 『일본어교육연구』 20, 한국일어교육학회, pp. 289-304.
- 이준서·한경수·노용기(2020) 「빅데이터 기반 다중언어 문화이미지프레임망 구축 구상」, 『일본어학연구』 65, 한국일본어학회, pp.131-142.
- 이준서 (2021) 「컬처마이닝(Culture Mining) 소고(小考) -일본어학 기반 융복합연구를 중심으로-」 『일본어학연구』 70, 한국일본어학회, pp.127-143.
- 이준서(2021) 「R컬처마이닝」 박문사.
- Church, K., W. Gale, P. Hanks, and D. Hindle (1991), "Using Statistics in Lexical Analysis", in U. Zernik (ed.), Lexical Acquisition: Exploiting on-line resources to build a lexicon. Hillsdale: Lawrence Erlbaum, pp.115-164.
- Fillmore C(1975) An Alternative to Checklist Theories of Meaning", Proceedings of the First Annual Meeting of the Berkeley Linguistics Society, pp. 123-131.
- Fillmore C(1977) Scenes-and-frames semantics, Linguistic Structures Processing, North-Holland, Amsterdam, pp. 55-81.
- Fillmore C(1982) Frame Semantics. In Linguistic Society of Korea (ed.), Linguistics in the Morning Calm. Seoul, Hanshin, pp.111-138.
- Google ML Kit – Image labeling, <https://developers.google.com/ml-kit/vision/image-labeling>
- Tensorflow Lite, <https://www.tensorflow.org/lite>
- Li Deng, Dong Yu, and et. al (2014). Deep learning: methods and applications. Foundations and Trends® in Signal Processing 7, 3–4 (2014), 197–387.
- Ian Goodfellow, Yoshua Bengio, and Aaron Courville(2016). Deep Learning. MIT Press. <http://www.deeplearningbook.org>
- Benigno Uribe, Marc-Alexandre Coté, Karol Gregor, Iain Murray, and Hugo Larochelle(2016). Neural autoregressive distribution estimation. Journal of Machine Learning Research 17, 205 (2016), 1–37.
- Hugo Larochelle and Iain Murray(2011). neural autoregressive distribution estimator. In Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics. 29–37.
- Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio(2014). Generative adversarial nets. In NIPS. 2672–2680.
- Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Andrei A Rusu, Joel Veness, Marc G Bellemare, Alex Graves, Martin Riedmiller, Andreas K Fidjeland, Georg Ostrovski, and et. al(2015). Human-level control through deep reinforcement learning. Nature 518, 7540 (2015), 529.

< 要 旨 >

ディープラーニングアルゴリズムを適用したカルチャーマイニング

本稿は最近、コンピュータビジョンおよび自然語処理など主要研究分野で多くの関心を集めているディープラーニング基盤イメージ学習データセットを活用して文化イメージフレーム網を改善しようと構想した論文だ。特にイメージにコンボリューションフィルターを使用して計算が速く、特定オブジェクトだけでなく背景を含むイメージ全体を考慮するCNNは、本カルチャーマイニング研究の文化イメージフレームを構成する文化要素抽出に非常に適したアルゴリズムといえる。特に、ディープラーニング実験用学習およびテストデータセットで検証された精製されたイメージ形態のイメージを活用することによって、(1)タギング情報の信頼性、(2)イメージ分割(segmentation)方式の不正確性、(3)イメージの重複性問題など既存研究の限界を大きく克服し、より精巧なカルチャーマイニング研究に寄与できるだけでなく、これを通じて構築されるカルチャーマイニングDBは究極的には文化要素抽出自動化のための学習データとして今後多様な活用価値を含んでいる。

論文分野： 意味論(Semantic)

キーワード：ディープラーニング、文化要素抽出システム (CEMS)、文化イメージフレームネットワーク (CIFN)、文化要素(CE)、文化イメージフレーム、CNN, RNN

■ 이준서(李竣瑞)

성결대학교 글로벌물류학부 교수
jslee@sungkyul.ac.kr

■ 임상순(林尙諄)

성결대학교 컴퓨터공학부 조교수
jslee@sungkyul.ac.kr

■投稿日	：	2022년	6월	30일
■審査開始	：	2022년	7월	12일
■審査完了	：	2022년	7월	27일
■掲載確定	：	2022년	8월	29일